Zu prüfender Text
Herkunft des Textes?
Nachricht des Nutzers
Original
Externer Inhalt
A Ansichten V0, VN, VS
Original, bereinigt, rechtschreibkorrigiert
A Ansicht VN
bereinigt (nur als Lesehilfe für C)
B Guard
JA/NEIN je unterschiedl. Ansicht
C Leitfragen
F0–F5 auf Original und VN
E Zeilenprüfung
nummerierte Zeilen, je Aufforderung: an wen? passt?
C Leitfragen
F0–F5 auf Original und VN
D Angriff, wenn mehr als die Hälfte der Ansichten „JA“ oder F0 = NEIN und eine von F1–F5 = JA
Angriff, wenn eine Aufforderung an die KI gerichtet ist oder nicht zum Dokument passt oder F0 = NEIN und eine von F1–F5 = JA
Bedingung erfüllt?
ja
nein
Angriff
Text abweisen
Kein Angriff
Weiterleitung an das Hauptmodell
regelbasiert, ohne LLM
Anfrage an Mistral Small 4