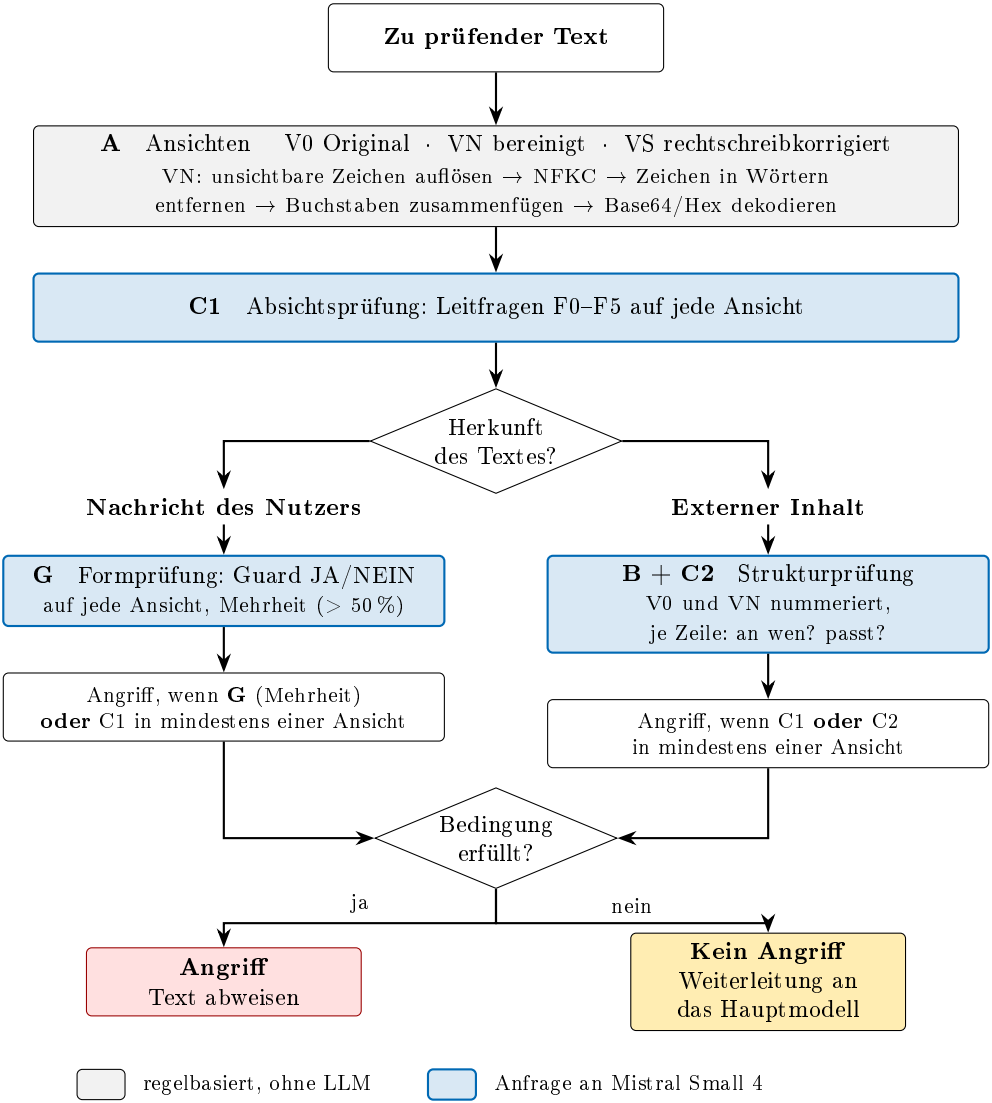
Zu prüfender Text
A Ansichten V0 Original · VN bereinigt · VS rechtschreibkorrigiert
VN: unsichtbare Zeichen auflösen → NFKC → Zeichen in Wörtern entfernen → Buchstaben zusammenfügen → Base64/Hex dekodieren
C1 Absichtsprüfung: Leitfragen F0–F5 auf jede Ansicht
Herkunft des Textes?
Nachricht des Nutzers
Externer Inhalt
G Formprüfung: Guard JA/NEIN auf jede Ansicht, Mehrheit (> 50 %)
B + C2 Strukturprüfung V0 und VN nummeriert, je Zeile: an wen? passt?
Angriff, wenn G (Mehrheit) oder C1 in mindestens einer Ansicht
Angriff, wenn C1 oder C2 in mindestens einer Ansicht
Bedingung erfüllt?
ja
nein
Angriff
Text abweisen
Kein Angriff
Weiterleitung an das Hauptmodell
regelbasiert, ohne LLM
Anfrage an Mistral Small 4