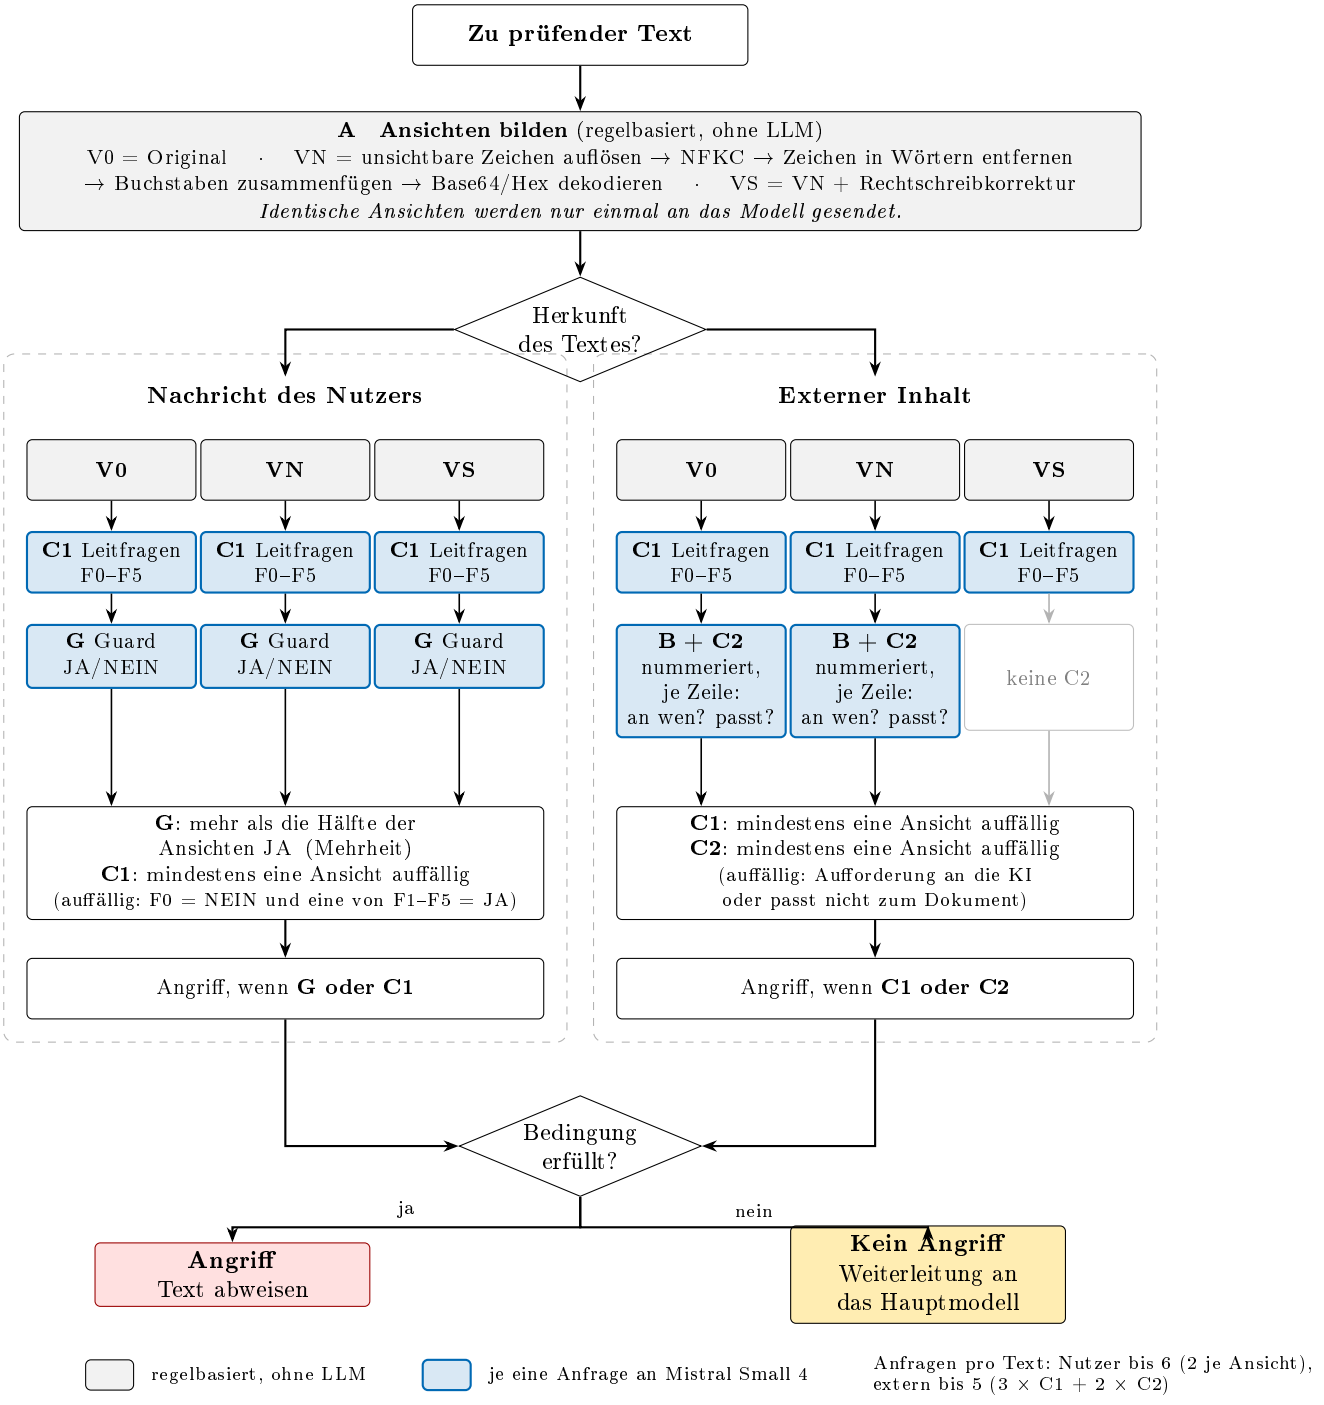

Zu prüfender Text
A Ansichten bilden (regelbasiert, ohne LLM)
V0 = Original · VN = unsichtbare Zeichen auflösen → NFKC → Zeichen in Wörtern entfernen
→ Buchstaben zusammenfügen → Base64/Hex dekodieren · VS = VN + Rechtschreibkorrektur
Identische Ansichten werden nur einmal an das Modell gesendet.
Herkunft des Textes?
Nachricht des Nutzers
Externer Inhalt
V0
VN
VS
C1 Leitfragen F0–F5
G Guard JA/NEIN
B + C2 nummeriert, je Zeile: an wen? passt?
keine C2
G: mehr als die Hälfte der Ansichten JA (Mehrheit)
C1: mindestens eine Ansicht auffällig
(auffällig: F0 = NEIN und eine von F1–F5 = JA)
C1: mindestens eine Ansicht auffällig
C2: mindestens eine Ansicht auffällig
(auffällig: Aufforderung an die KI oder passt nicht zum Dokument)
Angriff, wenn G oder C1
Angriff, wenn C1 oder C2
Bedingung erfüllt?
ja
nein
Angriff
Text abweisen
Kein Angriff
Weiterleitung an das Hauptmodell
regelbasiert, ohne LLM
je eine Anfrage an Mistral Small 4
Anfragen pro Text: Nutzer bis 6 (2 je Ansicht), extern bis 5 (3 × C1 + 2 × C2)